

# Aprendizaje Supervisado

## **Docentes:**

- **Dra. Ing. Karim Nemer**
- **Dr. Lic. José Robledo**

# Cuarta Clase

# Cuarta Clase: 02/07/2022

- Introducción al ML
- Etapas en la aplicación del ML
- Aprendizaje supervisado.
  - Repaso: Regresión Lineal y Polinomial, Regresión Logística, Naive Bayes.
  - Repaso: Perceptrón.
- Support Vector Machines.
  - SVC/SVR. Datos no linealmente separables. Función de costo.
- Ensemble learning.
  - Repaso: Decision Trees
  - Random Forest, Bagging, Boosting, Voting.
- Redes neuronales.
  - Perceptrón multicapa.
- Sistemas de recomendación.
  - Filtrado colaborativo.
- “Buenas” prácticas en la aplicación de ML

# **Sistemas de recomendación (Introducción)**

# Sistemas de recomendación: ejemplos

Google

mach



Basado en tu última visita Ver historial

Top Sellers in Toys for you

The screenshot shows the Amazon Prime Video interface with a focus on game DLC recommendations. The top navigation bar includes 'Inicio', 'Series', 'Películas', and 'Novelas'. Below this, a red banner reads 'DLC FOR YOUR GAMES'. Four game covers are displayed with their respective discounts and prices:

Game Title	Discount	Original Price (ARS\$)	Current Price (ARS\$)
ENDLESS SPACE 2	-50%	39,99	19,99
CIVILIZATION VI	-75%	395,99	98,99
PALADINS	-67%	1.583,00	522,39
KUPE	-75%	431,99	107,99

- ▶ Google
- ▶ MercadoLibre
- ▶ Amazon
- ▶ Netflix
- ▶ PrimeVideo
- ▶ Steam
- ▶ Facebook
- ▶ Instagram
- ▶ ...

# Sistemas de Recomendación: objetivos

Los sistemas de recomendación se centran en:


- *items*, para eCommerce
- *contenido*, para eLearning, noticias, streaming, etc.
- *links*, para navegación

en general, se habla de ítems como término genérico.

*El objetivo general de estos sistemas es el de guiar a los usuarios a tomar decisiones.*

# Tipos de Sistemas de Recomendación

- **Basados en contenido:** tratan el problema de manera específica para cada usuario y "aprenden" una clasificación de lo que a un usuario le gusta basado en las características (contenido) de un ítem.
- **Filtros colaborativos:** se basan en la idea que los usuarios que coinciden en el pasado lo harán en el futuro y que les gustarán ítems similares.
- **Basados en el conocimiento:** el usuario proporciona explícitamente parámetros del producto que quiere
- **Basados en cuestiones demográficas**
- **Sistemas híbridos**



# Filtros colaborativos

Combina usuarios con intereses similares:

- Se podría requerir de muchos usuarios para que las posibilidades de encontrar un par con intereses en común.
- Tiene que existir un método sencillo para reflejar los intereses de los usuarios.
- Se necesita de un algoritmo eficiente para combinar a los usuarios con gustos similares.



# Filtros colaborativos: cómo funcionan?

## INPUT

Usuarios generan puntuaciones a un conjunto de ítems (implícita o explícitamente): matriz de puntuaciones usuario-ítem

## OUTPUT

- Predicción (numérica) indicando cuánto a un usuario le gusta un ítem
- Una lista con N ítems recomendados por usuario

## Filtros colaborativos: Vecindarios basado en usuarios

► Dado un usuario (Claudia) y un ítem que todavía no se ha asignado un puntaje, se debe:

- encontrar el conjunto de usuarios que más se parecen a Claudia (usuarios a los que les gustan ítems similares) y han puntuado el objeto
- usar sus puntuaciones para predecir si a Claudia le gustará el ítem
- aplicar este proceso sobre todos los objetos que Claudia no ha puntuado y recomendar los que tienen mayor puntuación

	Item1	Item2	Item3	Item4	Item5
Claudia	5	3	4	4	
Usuario1	3	1	2	3	3
Usuario2	4	3	4	3	5
Usuario3	3	3	1	5	4
Usuario4	1	5	5	2	1

# Similitud entre usuarios

Coeficiente de correlación (Pearson correlation)

$$sim(a, b) = \frac{\sum_{p \in P} (r_{a,p} - \bar{r}_a)(r_{b,p} - \bar{r}_b)}{\sqrt{\sum_{p \in P} (r_{a,p} - \bar{r}_a)^2} \sqrt{\sum_{p \in P} (r_{b,p} - \bar{r}_b)^2}}$$

donde:

- $a$  y  $b$  son usuarios;
- $r_{a,p}$  es la puntuación del usuario  $a$  al ítem  $p$ ;
- y  $P$  es el conjunto de ítems que ya han sido puntuados por  $a$  y  $b$ .

# Similitud entre usuarios

$$\text{sim}(a, b) = \frac{\sum_{p \in P} (r_{a,p} - \bar{r}_a)(r_{b,p} - \bar{r}_b)}{\sqrt{\sum_{p \in P} (r_{a,p} - \bar{r}_a)^2} \sqrt{\sum_{p \in P} (r_{b,p} - \bar{r}_b)^2}}$$

	Item1	Item2	Item3	Item4	Item5
Claudia	5	3	4	4	
Usuario1	3	1	2	3	3
Usuario2	4	3	4	3	5
Usuario3	3	3	1	5	4
Usuario4	1	5	5	2	1

**$\text{sim}(\text{Claudia}, \text{Usuario1}) = 0.8392$**

**$\text{sim}(\text{Claudia}, \text{Usuario2}) = 0.6063$**

**$\text{sim}(\text{Claudia}, \text{Usuario3}) = 0$**

**$\text{sim}(\text{Claudia}, \text{Usuario4}) = -0.7681$**

# Similitud entre usuarios

Coeficiente de correlación

$$pred(a, p) = \bar{r}_a + \frac{\sum_{b \in N} sim(a, b) (r_{b,p} - \bar{r}_b)}{\sum_{b \in N} sim(a, b)}$$

donde:

- N es el conjunto de "vecinos"
- p es un ítem

$$pred(Claudia, item5) = 4 + \frac{0,85 (3 - 2,4) + 0,7 (5 - 3,8)}{0,85 + 0,7}$$

# Filtros colaborativos: Vecindarios basado en ítems

Se usan las semejanzas entre los ítems (y no entre los usuarios) para hacer las predicciones.

Por ejemplo, busquemos los ítems parecidos al *Item5*. Ahora usamos las puntuaciones que Claudia le asignó a tales ítems para darle un valor al *Item5*.

	Item1	Item2	Item3	Item4	Item5
Claudia	5	3	4	4	
Usuario1	3	1	2	3	3
Usuario2	4	3	4	3	5
Usuario3	3	3	1	5	4
Usuario4	1	5	5	2	1

# Similitud entre ítems

Distancia (ajustada) del coseno

$$sim(a, b) = \frac{\sum_{u \in U} (r_{u,a} - \bar{r}_u)(r_{u,b} - \bar{r}_u)}{\sqrt{\sum_{u \in U} (r_{u,a} - \bar{r}_u)^2} \sqrt{\sum_{u \in U} (r_{u,b} - \bar{r}_u)^2}}$$

donde:

- $a$  y  $b$  son ítems;
- $r_{u,a}$  es la puntuación del usuario  $u$  al ítem  $a$ ;
- y  $U$  es el conjunto de usuarios que han puntuado a los ítems  $a$  y  $b$ .

# Similitud entre ítems

$$\text{pred}(u, \text{item}_j) = \bar{r}_u + \frac{\sum_{\text{item}_i \in N} \text{sim}(\text{item}_i, \text{item}_j) r_{u, \text{item}_i}}{\sum_{\text{item}_i \in N} \text{sim}(\text{item}_i, \text{item}_j)}$$

donde:

- N es el conjunto de "vecinos"
- u es un usuario

$$\text{pred}(\text{Claudia}, \text{item}_5) = \bar{r}_{\text{Alice}} + \frac{\sum_{\text{item}_i \in N} \text{sim}(\text{item}_i, \text{item}_5) r_{\text{Claudia}, \text{item}_i}}{\sum_{\text{item}_i \in N} \text{sim}(\text{item}_i, \text{item}_j)}$$



# Filtros colaborativos: Preprocesamiento

Para que estos sistemas de recomendación sean escalables, es necesario aprender el modelo "offline".

- Calcular offline todas las similitudes entre pares de objetos
- Calcular la predicción en tiempo real (pred de la slide anterior)
- El vecindario (N) suele ser bastante pequeño (el usuario puntúa pocos objetos)

Este preprocesamiento funciona en CF por ítems (y no en CF por usuarios): las similitudes entre ítems suelen ser más estables que entre usuarios.

# Filtros colaborativos: Preprocesamiento

*Requerimientos de memoria:* si consideramos  $n$  ítems, tendremos  $n^2$  similitudes.

En la práctica, la matriz es dispersa (muchos pares de ítems que no tienen similitud).

Se suelen usar reducciones fijando un umbral mínimo de "co-ratings": se eliminan ítems que tienen pocas puntuaciones comunes, usando al menos  $n'$  usuarios.

Se puede también limitar el tamaño del vecindario ( $N$ ).

# Filtros colaborativos: Problemas

## *Cold start problem:*

- ¿Cómo recomendamos nuevos ítems?
- ¿Qué le recomendamos a usuarios nuevos?

## *Soluciones inmediatas:*

- Forzar a los usuarios a puntuar un conjunto de objetos (-1)
- Emplear otro método para la estos casos (basado en contenido, información demográfica o recomendaciones no personalizadas)

# Filtros colaborativos: Problemas

Problemas con los vecindarios:

El conjunto de usuarios ítems similares puede ser muy pequeño. Lo que produce malas predicciones.

Alternativas:

- CF recursivo
  - Transitividad entre vecinos

**Demo time**  
**(demo\_11\_recommender\_systems)**


# **Estrategias para Machine Learning**

# Estrategias para Machine Learning

## *Referencias:*

- Andrew Ng. “Machine Learning Yearning”. Draft, 2018.

- Experiencia



# Honest Machine Learning

## *Google:*

- Cantidades astronómicas de datos
- Ejércitos de ingenieros
- Hectáreas de GPUs, memoria, etc.



## *Vos:*

- 1500 datos ruidosos
- Una fracción de tu tiempo
- Una notebook del año 2016



# Estrategias para Machine Learning

Queremos aplicar ML sobre un problema, de manera rápida y exitosa.


Lamentablemente, nuestro algoritmo anda mal. ¿Qué hacer?

Opciones:

- Recolectar más datos, o datos más diversos
- Preprocesamiento: ingeniería de features, reducción de dimensionalidad, normalización, etc.
- Modelos de clasificación
- Parámetros/arquitectura: modelos más simples, o más complejos
- Entrenamiento

Hay que saber elegir!!

# Método iterativo



# Setup: Preparación de los Conjuntos de Datos

- **Training:** Entrenamiento
- **Validación:** Para ajustar hiperparámetros, seleccionar features, analizar errores, etc.
- **Prueba:** Para obtener números finales de evaluación. **Nunca** para tomar decisiones.

Validación y prueba **deben** responder a la misma distribución.

**Entrenamiento:** no necesariamente.

# Setup: Tamaño de los datasets

- ✓ Machine Learning clásico:
  - ✓ División de los datos ~70/10/20
- ✓ Grandes cantidades de datos:
  - ✓ unos pocos miles para desarrollo/prueba.
- ✓ Resolución: El tamaño del dataset indica la “resolución” de la precisión
  - ✓ 100 elementos: 1%
  - ✓ 500: 0.2%
  - ✓ 1000: 0.1%
  - ✓ 10000: 0.01%

# Setup: Métricas

- *Precisión:*
  - Poco informativa para problemas desbalanceados
- *Precision/recall/F1:*
  - *Binaria:* Focalizar el problema en una de las dos clases.
  - *Multiclase:* Permite regular la importancia de cada clase (weighted macro-average).
- *Balanced Accuracy (Recall Macro Average)*
- *ROC AUC y AUCPR:*
  - Más expresiva: evalúa probs/scores asignadas a todas las clases, no la predicción.

# Setup: Métricas de optimización vs. satisfacción

- Establecer una **única** métrica numérica, cuyo objetivo es optimizar.
- Métricas secundarias:
  - Velocidad
  - Instancias sensibles que no pueden ser etiquetadas incorrectamente.
  - Valores mínimos de precision/recall para clases específicas.
- Definir criterios de “satisfacción” para las métricas secundarias.

# Setup: Baselines

- Clasificadores “bobos” para calcular valores mínimos para las métricas.
  - Clase mayoritaria
  - Random uniforme
  - Random respetando distribución
- A veces también se pueden calcular upper bounds teóricas.

# Setup: Rápido!

- Definir rápidamente los conjuntos de datos y las métricas objetivo.
- Permite iniciar el ciclo iterativo.
- Luego, los resultados y su análisis pueden indicar la necesidad de modificaciones:
  - a. Los datos no reflejan la aplicación real: actualizar dev/test
  - b. Overfitting en dev: se iteró muchas veces, actualizar dev.
  - c. Las métricas no reflejan los objetivos.




# Setup: Registro de Experimentos

- Historial de experimentos realizados.
- Registrar información necesaria para la reproducibilidad:
  - Fecha del experimento
  - Configuración del modelo
  - Resultado de las evaluación

# Método Iterativo


## Primera Iteración: Sistema Básico

- No empezar tratando de construir el sistema perfecto.
- Construir y entrenar un sistema básico lo más rápido posible.
- Evaluarlo y estudiarlo para decidir en qué direcciones avanzar.



# Primera Iteración: Modelo de Clasificación

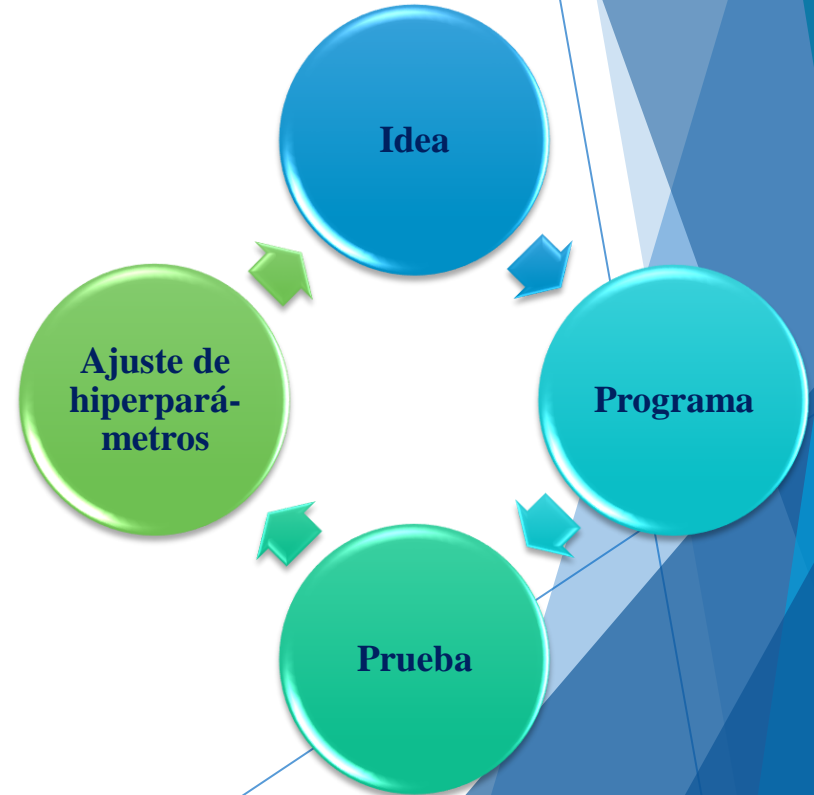
- Se pueden probar varios modelos de clasificación
- Empezar eligiendo el que mejor ande sin ninguna configuración.
- No empezar **NUNCA** con redes neuronales.
- No casarse con un único modelo.



# Ajuste de Hiperparámetros

## *Opciones:*

- Búsqueda manual.
- Búsqueda exhaustiva (grid-search): todas las combinaciones posibles de valores.
- Aleatoria (randomized): sampleando valores o combinaciones.
- Development vs. Cross Validation



# Ajuste de Hiperparámetros

Estrategias:

- ¡Leer documentación!
- Empezar con búsqueda manual. Elegir parámetros más relevantes.
- Búsqueda aleatoria, con un espectro mayor.
- Seguir con búsqueda exhaustiva. Probar pocas combinaciones.
- Iterar.
- Guardar mejores configuraciones (no sólo la mejor).

# Evaluación: Sesgo y Varianza

- **Sesgo (bias):** Error en el conjunto de entrenamiento.
- **Varianza (variance):** Error en el conjunto de development.
- **Error total:** bias + variance.
- Hacer Machine Learning = Bajar el error total.



# Evaluación: Sesgo

- **Sesgo alto:** el clasificador **ni siquiera** es capaz de aprender los datos de entrenamiento.
  - Anda peor que un sistema que memoriza los puntos de entrenamiento.
  - ¿Cuánto quiere decir alto?
  - Depende del problema y de los valores a los que aspiramos.
  - Normalmente el sesgo **se puede reducir a cero. Se puede pero no necesariamente se quiere.**

**PRIMER OBJETIVO DEL ML: CONTROLAR EL SESGO.**

# Evaluación: Reducción de Sesgo

- El sistema no logra aprender el conjunto de entrenamiento. No es lo suficientemente “expresivo” (underfitting).
- Soluciones:
  - **Modelo más grande:** agregar parámetros, capas, componentes, etc.
  - **Modelo menos regularizado:** salir del underfitting.
  - **Características más expresivas:** más dimensiones.
  - **Modelo nuevo:** clasificador diferente, otra arquitectura.



# Evaluación: Varianza

- **Sesgo bajo control:** Puedo hacerlo tan bajo como quiera.
- **Varianza alta:** No generaliza. No “aprende”. Memoriza. (overfitting)
- ¿Cuánto es varianza alta?
  - Nuevamente, depende del problema y de nuestros objetivos.
  - Con el sesgo controlado, la varianza es directamente proporcional al error total.
  - Con el sesgo controlado, **varianza cero = sistema perfecto.**
- **NUEVO OBJETIVO: Bajar la varianza tanto como se pueda = HACER ML.**

# Evaluación: Reducción de Varianza

- ✓ El sistema no logra generalizar a partir del conjunto de entrenamiento.
- ✓ Posibles soluciones:
  - ✓ **Más datos de entrenamiento.** No hay de dónde aprender.
  - ✓ **Mejores features:** Facilitar al modelo el acceso a información valiosa.
  - ✓ **Bajar expresividad:** Regularización, early stopping, menos params., etc.
  - ✓ **Modelo nuevo:** clasificador diferente, otra arquitectura.

# Análisis de Error

- ¿En qué se equivoca el modelo?
- Inspeccionar elementos mal clasificados.
- ¿Porqué se clasifica mal?
  - Ver la probabilidad / score de la clase correcta.
  - Ver features activos. Ver valores cercanos en instancias de entrenamiento.
  - Ver qué modificaciones del elemento hacen que se clasifique bien.
- Inspeccionar elementos **peor** clasificados (en base a prob/score)



# Análisis de Error

- Hacer una lista de ejemplos mal clasificados. (e.g., 50 de dev)
- Inspeccionar cada ejemplo. Identificar fuentes de error.
- Para cada fuente de error, identificar importancia y costo estimado.

Audio clip	Loud background noise	User spoke quickly	Far from microphone	Comments
1	✓			Car noise
2	✓		✓	Restaurant noise
3		✓	✓	User shouting across living room?
4	✓			Coffeeshop
% of total	75%	25%	50%	

# Análisis de Error (Error Analysis)

- Subdivisión de development:
  - Eyeball dev set (~100 instancias)
  - Blackbox dev set (el resto)
  - Rotar cada tanto!
- Errores en el dataset:
  - Evaluar su impacto.
  - Si es importante, corregir en **todos** los datasets.

# Inspección del Modelo



- Estudiar los parámetros del modelo una vez aprendido.
- Features más influyentes para cada clase.
- Fronteras de decisión.



# Inspección del Modelo

- Modelos fácilmente inspeccionables:
  - **Decision Trees**
  - **Naive Bayes:** probabilidad de cada feature dada la clase (y prior de la clase)
  - **Logistic Regressions:** score de cada feature para cada clase (y bias o intercept)
- Más complicado:
  - **Random Forests:** son muchos árboles para ver!
  - **SVMs:** ver con qué features está más alineado el hiperplano.
  - **Redes Neuronales:** usar inputs para ver cómo reacciona la red.

# Fork (Bifurcación)





# Bifurcación

- Empezar a mantener dos o más sistemas diferentes en simultáneo.
- Cada uno tiene su ciclo de experimentación.
- Con el tiempo, las configuraciones divergen.
- Ejemplo:
  - SVM / LR
  - Red neuronal: MLP / RNN / CNN

# Retrospectivas

- **Revisar ideas previas**, tanto las aceptadas como las rechazadas.
- **Ablation Tests**: medir el impacto de cada componente del sistema actual.
- **Hiperparameter retuning**: Volver a hacer ajuste de hiperparámetros
- **Reconsiderar** viejas ideas




# Aumentación de Datos (Data Augmentation)

- Generar datos artificiales en base a los datos que tenemos.
- Las transformaciones deben preservar las etiquetas
- Imágenes: rotación, escala, espejado, cambio de color, etc.
- Texto: más difícil! sinónimos, traducción bidireccional, etc.


# **Ingeniería del Software en Machine Learning**

# Diferencias con los sistemas tradicionales


## Traditional Programming



## Machine Learning



# Workflow de desarrollo de software tradicional vérsus desarrollo de machine learning



# Testing en machine learning?

- **Model evaluation:** métricas, gráficos, estadísticas que resumen el comportamiento del modelo en los conjuntos de dev/test.
- **Model testing:** verificación explícita de comportamientos que esperamos de nuestro modelo
  - **Pre-train tests**
  - **Post-train tests**

# Testing del Modelo: tests de pre-entrenamiento

Tests que se pueden ejecutar sin la necesidad de entrenar el modelo sobre todo el dataset.

- **Tamaño del output del modelo:** verificar que la longitud del vector? de salida del modelo esté alineado al tamaño de los labels del dataset
- **Rangos de salida:** validar tipos y rangos de valores según las expectativas. Por ejemplo, si el output es una probabilidad, asegurarse de que la suma será 1
- **La ejecución del modelo tiene sentido:** por ejemplo, asegurarse de que los pasos en gradient descent produzcan un descenso en el costo
- **Verificar data leakage**



# Testing del Modelo: tests de post-entrenamiento

Tests sobre resultados del modelo ya entrenado.

## Invariance Tests

- Describen perturbaciones en la entrada del modelo que no deberían modificar la salida.
- Similar al concepto de *data augmentation*, donde se modifica la entrada durante el training pero se preservan las etiquetas.
- Ejemplo: para un modelo de análisis de sentimiento:
  - Juan es un buen tipo
  - José es un buen tipo


# Testing del modelo: tests de post-entrenamiento

Tests sobre resultados del modelo ya entrenado.

## Tests de expectativa direccional

- Nos permiten definir perturbaciones en la entrada que deberían afectar de cierta forma la salida del modelo.
- Por ejemplo, para un modelo que predice el precio de inmuebles:
  - Aumentar el número de habitaciones que tiene una casa, manteniendo constante el resto de sus atributos, no debería causar un descenso de su precio
  - Reducir la superficie cubierta ( $m^2$ ) de una propiedad, no debería aumentarle su valor

# Nuevo workflow de desarrollo de machine learning



**Demo time**  
**(demo\_12\_ML\_practices)**

**FIN**